



Traitement Automatique du Langage Naturel

Dr Pengwendé ZONGO
UFR-ST

Information

UE : Traitement des données (6 crédits) :

ECU : TALN (2 crédits) :

- **Volume Horaire de 16h dont**
- **Cours : 12h**
- **TD/TP : 4h**

Objectifs

- Connaître les concepts relatifs au traitement automatique du langage naturel (TALN).
- Proposer une architecture de TALN
- Développer un modèle de TALN

Plan du cours :

I- Principes fondamentaux du TALN

1. Définitions
2. Aperçu historique
3. Les différentes techniques utilisées avec le NLP
4. Cas d'utilisation du NLP

II- Architecture d'une application de TALN

1. Prétraitement des données
2. Développement de l'algorithme

III- Les outils Python pour la création d'un modèle NLP

1. nltk
2. spaCy

Introduction

L'Intelligence Artificielle, en tant que partie prenante du processus de digitalisation de l'entreprise, connaît un essor impressionnant sur grand nombre de secteurs d'activité et ses cas d'application se multiplient. Un des grands axes de développements de l'IA est constitué par la prise en compte et la mise en valeur des données non structurées autrefois peu utilisées. Une grande partie de ces données non structurées sont au format de textes, comme

- Le contenu des sites internet et leurs métadonnées
- Les messages des réseaux sociaux
- Les logs des machines
- Les emails
- Les articles, documents, présentations au sein d'une entreprise
- Les livres publiés

Introduction

Aujourd'hui, l'Intelligence Artificielle peut venir enrichir les capacités d'une entreprise en tirant partie de ces données textuelles, grâce à une technique appelée « Natural Language Processing » ou Traitement Automatique du Langage Naturel.

I- Principes fondamentaux du TALN

1. Définitions

Le Traitement Automatique du Langage Naturel (TALN) en français ou **Natural Language Processing (NLP)** en anglais, désigne la capacité d'un programme informatique à **comprendre le langage humain**. Il s'agit d'une composante de l'intelligence artificielle (IA) qui traite le langage naturel tel qu'il est parlé et écrit.

Le NLP appartient à la fois au domaine de l'informatique et de la linguistique.

I- Principes fondamentaux du TALN

1. Définitions

Le NLP appartient à la fois au domaine de l'informatique et de la linguistique.




Fig. 1 : Vue d'ensemble du NLP dans le domaine de l'IA.

I- Principes fondamentaux du TALN

1. Définitions

Véronis (2001) ; Tellier (2010) ; Yvon (2010) définissent le TALN est l'ensemble des recherches et développements visant à modéliser et à reproduire, à l'aide de machines, la capacité humaine à produire et à comprendre des énoncés linguistiques dans des buts de communication »

I- Principes fondamentaux du TALN

1. Définitions

Il ne doit pas être confondu avec la linguistique informatique, qui vise à comprendre les langues au moyen d'outils informatiques.

Linguistique informatique ou linguistique computationnelle : modèles ou les formalismes linguistique développés dans le but d'une implantation informatique.

De ces définitions, nous pouvons retenir que l'essence même du NLP est de comprendre l'intention de l'utilisateur pour pouvoir lui apporter la réponse la plus adaptée à sa demande.

I- Principes fondamentaux du TALN

2. Aperçu historique

L'histoire récente du Traitement Automatique des Langues (TAL) ou Traitement Automatique du Langage Naturel (TALN) ou encore Natural Language Processing (NLP) en anglais date de la période de la guerre froide entre les Etats-Unis et la Russie. Les applications informatiques développées à cette période étaient liées au traitement automatique des conversations.

Les premières applications informatiques sont liées au traitement automatique des conversations. En 1950, dans son article fondateur de l'intelligence artificielle, "**Computing machinery and intelligence**", Alan Turing expose une méthode d'évaluation qui sera appelée par la suite "**test de Turing**" ou "**critère de Turing**". Ce test mesure le degré d'intelligence d'une machine, à partir de la capacité d'un programme conversationnel à se faire passer pour un être humain : dans un échange de messages écrits, un sujet humain doit déterminer si son interlocuteur est une machine ou non. La base employée est cependant fragile pour évaluer l'intelligence artificielle, car l'impression d'un unique utilisateur dépend de trop de facteurs liés au milieu ambiant pour être érigée en règle.

I- Principes fondamentaux du TALN

2. Aperçu historique

De 1970 à 1980 beaucoup de programmeurs ont commencé à écrire des "**ontologies conceptuelles**", qui consistaient à structurer l'information en données compréhensibles par l'ordinateur. Mais, c'est à partir des progrès des recherches dans le domaine du *Deep learning* que ce champ de recherche va connaître une véritable avancée.

En 2019, Google a introduit AutoML Natural Language en tant qu'extension de sa plateforme AutoML. Communiquer avec des machines devient finalement aussi simple que d'interagir avec un humain. Le but ultime du NLP est d'aider les ordinateurs à comprendre le langage aussi bien que nous. À mesure que nous avançons, le NLP continuera à stimuler des industries telles que l'apprentissage automatique, la robotique, les soins de santé, les services financiers, les automobiles liées, les maisons intelligentes, etc.

I- Principes fondamentaux du TALN

2. Aperçu historique

De nos jours, la qualité des applications développées dans ce domaine est forte appréciable. Cependant, qu'entendons nous par TAL? Le TAL est un domaine de recherche multidisciplinaire qui implique la linguistique, l'informatique et l'intelligence artificielle. Il est consacré à la manipulation automatique du langage naturel, comme la parole et le texte, par un logiciel. Le TAL vise à créer des outils de traitement de la langue naturelle pour diverses applications.

Jacquemin et Zweigenbaum définissent le TAL comme un domaine de recherche qui s'intéresse aux traitements informatisés en mettant en jeu le matériau linguistique [52]. Il vise à appliquer des programmes informatiques et des techniques de l'IA dans tous les aspects du langage humain.

I- Principes fondamentaux du TALN

2. Aperçu historique

En janvier 2018, des modèles d'intelligence artificielle développés par Microsoft et Alibaba réussissent chacun de leur côté à battre les humains dans un test de lecture et de compréhension de l'université de Stanford. Le traitement automatique du langage naturel imite la compréhension humaine des mots et des phrases et permet maintenant aux modèles d'apprentissage automatique de traiter de grandes quantités d'informations avant de fournir des réponses précises aux questions qui leur sont posées.

En novembre 2018, Google lance BERT, un modèle de langage.

En mai 2020, OpenAI, une société fondée par Elon Musk et Sam Altman, annonce le lancement de GPT-3, un modèle de langage à 175 milliards de paramètres diffusé comme *fork* d'une API commerciale.

I- Principes fondamentaux du TALN

3. Les différentes techniques utilisées avec le NLP

L'analyse syntaxique et l'analyse sémantique constituent les deux principales techniques utilisées pour le NLP.

□ Analyse syntaxique

En NLP, c'est un processus qui permet d'analyser une phrase ou un texte afin de comprendre sa structure grammaticale et les relations entre les mots, les phrases et les clauses. C'est une tâche fondamentale dans le traitement du langage naturel, car elle permet à l'ordinateur de comprendre le sens d'une phrase et d'en extraire des informations importantes.

I- Principes fondamentaux du TALN

3. Les différentes techniques utilisées avec le NLP

□ Analyse syntaxique

La syntaxe désigne la disposition des mots dans une phrase pour lui donner un sens grammatical. Le NLP l'utilise pour évaluer le sens d'une langue sur la base de règles grammaticales. Les techniques syntaxiques comprennent :

- **L'analyse syntaxique** : il s'agit de l'analyse grammaticale d'une phrase.
- **Segmentation des mots** : il s'agit de prendre une chaîne de texte et d'en déduire des formes de mots.

I- Principes fondamentaux du TALN

3. Les différentes techniques utilisées avec le NLP

□ Analyse syntaxique

- **La séparation des phrases** : il de placer des limites de phrases dans des textes volumineux.
- **Segmentation morphologique** : elle divise les mots en partie plus petits appelés morphèmes.
- **L'étymologie** : cette opération consiste à diviser les mots contenant une inflexion en formes de racines.

I- Principes fondamentaux du TALN

3. Les différentes techniques utilisées avec le NLP

□ Analyse sémantique

Ce type d'analyse va au-delà de la structure grammaticale d'une phrase et examine le sens des mots et leur relation les uns avec les autres. Il vise à extraire le sens de la phrase et à identifier les relations entre les entités et les événements.

Le NLP applique des algorithmes pour comprendre le sens et la structure des phrases. Les techniques sémantiques comprennent :

- **La désambiguïsation du sens des mots.** Cette technique permet de déduire la signification d'un mot en fonction du contexte.

I- Principes fondamentaux du TALN

3. Les différentes techniques utilisées avec le NLP

□ Analyse sémantique

- **Reconnaissance d'entités nommées.** Cette méthode détermine les mots qui peuvent être classés en groupes. C'est un processus qui consiste à prendre une chaîne de texte en entrée et à identifier les noms pertinents (personnes, lieux et organisations) qui sont mentionnés dans cette chaîne. L'algorithme utilisé par cette méthode est le **POS Tagging (logique d'annotation)** : c'est le processus de marquage d'un mot dans un texte (corpus) comme correspondant à une partie particulière du discours. Il est utilisé pour distinguer les différentes composantes d'une phrase (nom, verbe, etc.)

Je **vais** traiter un **devoir**

Sujet **Verbe** **Nom commun (COD)**

I- Principes fondamentaux du TALN

3. Les différentes techniques utilisées avec le NLP

□ Analyse sémantique

- **Génération de langage naturel.** Cette méthode utilise une base de données pour déterminer la sémantique des mots et générer un nouveau texte. Elle fait référence au processus d'utilisation d'algorithmes d'IA pour générer du texte en langage naturel similaire au texte écrit par l'homme. Cela peut être fait en entraînant un modèle sur un grand corpus de texte, tel qu'un ensemble de données de livres, d'articles ou de publications sur les réseaux sociaux, puis en utilisant le modèle pour générer un nouveau texte en fonction des modèles qu'il a appris à partir des données d'entraînement.

I- Principes fondamentaux du TALN

3. Les différentes techniques utilisées avec le NLP

□ Analyse sémantique

Il existe plusieurs types de modèles de génération de texte utilisés en NLP, notamment : **les modèles de chaînes de Markov, les réseaux neuronaux récurrents (RNN), les modèles de transformateur génératifs pré-entraînés (GPT), les modèles de transformateur-décodeur.**

- **Génération de texte : les modèles de chaînes de Markov**

Les modèles de chaînes de Markov sont basés sur l'idée que la probabilité qu'un mot apparaisse dans un texte dépend des mots précédents dans le texte. Ces modèles peuvent être utilisés pour générer un nouveau texte en sélectionnant des mots au hasard en fonction des probabilités apprises à partir des données d'entraînement.

I- Principes fondamentaux du TALN

□ Analyse sémantique

- **Génération de texte : les réseaux neuronaux récurrents (RNN)**

Les RNN sont un type de réseau neuronal conçu pour traiter des données séquentielles, telles que du texte. Ils peuvent être utilisés pour générer un nouveau texte en prédisant le mot suivant dans une phrase en fonction des mots précédents de la phrase.

- **Génération de texte : les modèles de transformateur génératifs pré-entraînés (GPT)**

les modèles GPT sont un type de réseau neuronal de transformateur qui est pré-entraîné sur une quantité massive de données textuelles et affiné sur une tâche spécifique, telle que la génération de texte.

I- Principes fondamentaux du TALN

□ Analyse sémantique

- **Génération de texte : les modèles de transformateur-décodeur**


Les modèles de transformateur-décodeur sont un type d'architecture de réseau neuronal utilisé pour la génération de texte. Ils se composent d'un encodeur qui traite le texte d'entrée et d'un décodeur qui génère le texte de sortie.

L'un des modèles les plus populaires et les plus puissants pour la génération de texte est GPT-3, qui est un modèle de transformateur pré-entraîné développé par OpenAI. GPT-3 a été entraîné sur une quantité massive de données textuelles et peut générer un texte très similaire à un texte écrit par l'homme.

I- Principes fondamentaux du TALN

□ Analyse morphologique

L'analyse morphologique consiste après segmentation du texte, à étudier la forme d'un mot pris isolément (sans contexte) et à déduire les informations dérivationnelles et inflectionnelles. Ainsi, l'analyseur doit générer pour le mot traité une ou plusieurs solutions morphologique décrites par les informations suivante : les suffixes, les préfixes, le radical, la forme canonique (lemme) ainsi que d'autres informations comme le genre grammatical (féminin, masculin), le nombre (singulier, pluriel) ou le temps (verbe conjugué au présent, au passé parfait,...etc.).



I- Principes fondamentaux du TALN

4. Cas d'utilisation du NLP

Les secteurs d'application de l'IA dans notre vie quotidienne sont quasiment illimités. De ce fait, en tant que technologie reliée à l'IA, le NLP peut aider dans de nombreuses tâches.

- **La traduction automatique** : elle est l'une des premières applications du NLP. Il existe quatre types de traduction automatique basés sur le NLP.
 - ✓ **La traduction automatique statistique** : elle dépend de l'étude de données bilingues pour trouver une correspondance entre le mot de la langue d'entrée et celui de la langue souhaitée.
 - ✓ **La traduction automatique basée sur les règles** : elle traduit les textes en se basant sur les règles grammaticales des deux langues.

I- Principes fondamentaux du TALN

4. Cas d'utilisation du NLP

- ✓ **La traduction automatique hybride** : elle combine en quelque sorte les deux méthodes précédentes, et elle utilise une mémoire de traduction.
- ✓ **La traduction automatique neuronale**: elle s'appuie sur des modèles de réseaux de neurones artificiels pour créer des modèles statistiques. C'est par exemple le cas de **DeepL** qui se base sur le Deep Learning pour la traduction automatique naturelle.
- **Les agents conversationnels** : tels que les chatbots et les assistants vocaux, ce sont des exemples qui reflètent parfaitement la capacité des programmes informatiques à comprendre le langage humain. Un chatbot est une plateforme qui permet aux clients d'une entreprise de commander des informations.

I- Principes fondamentaux du TALN

4. Cas d'utilisation du NLP

Par définition, le robot conversationnel reçoit donc une entrée en langage naturel et le NLP lui permet d'interpréter cette information.

De la même manière, les assistants vocaux et les robots assistants reçoivent des entrées vocales. Ces systèmes utilisent le NLP pour répondre aux commandes et agir en fonction. C'est par exemple la compréhension du langage humain qui permet à Alexa d'allumer la lumière, sur commande.


- **La détection des fake news** : Le NLP a été utilisée par le NLP Group du MIT pour **vérifier l'authenticité d'une source d'informations**.
- **La détection des spams** : Certaines sociétés comme Yahoo et Google utilisent cette technologie pour **stopper les spams** avant même qu'ils n'entrent dans la boîte de réception.

I- Principes fondamentaux du TALN

4. Cas d'utilisation du NLP

- **L'analyse des sentiments (Opinion mining) :** L'opinion mining, est un type particulier de classification de textes, sa particularité réside dans sa capacité à identifier automatiquement des informations subjectives, telles que des opinions, des émotions ou des sentiments dans le texte. L'une des tâches les plus élémentaires de l'opinion mining est la classification de la polarité, c'est-à-dire de classer si l'opinion exprimée est positive, négative ou neutre

SENTIMENT ANALYSIS



Given text, sentiment analysis classifies its emotional quality.


I- Principes fondamentaux du TALN

4. Cas d'utilisation du NLP

- **Classification des textes** : c'est un processus de classification de morceaux de texte en différentes catégories. C'est l'une des tâches TALN les plus simples mais les plus largement utilisées.
- **Synthèse de texte** : le résumé de texte en traitement du langage naturel (NLP) fait référence au processus de génération automatique d'une version plus courte d'un document texte plus long tout en préservant ses informations les plus importantes. L'objectif du résumé de texte est de réduire la longueur d'un texte tout en conservant les informations les plus importantes, ce qui peut être utile dans une variété d'applications, telles que le résumé de contenu pour des sites Web ou des médias sociaux, le résumé de longs documents et le résumé d'articles de presse.

I- Principes fondamentaux du TALN

4. Cas d'utilisation du NLP



II- Architecture d'une application de TALN

Le langage humain regorge d'ambiguïtés qui rendent extrêmement difficile la création de logiciels capables de déterminer avec précision le sens de données textuelles ou vocales. Les homonymes, les homophones, le sarcasme, les expressions idiomatiques, les métaphores, les exceptions de grammaire et d'usage, les variations dans la structure des phrases ne sont que quelques-unes des irrégularités du langage humain qui nécessitent de nombreuses années d'apprentissage pour l'homme, mais que les applications basées sur le langage naturel doivent apprendre à reconnaître et à comprendre avec précision dès le départ, si l'on veut qu'elles soient utiles.

Néanmoins, cela ne doit pas être un handicap pour le développement d'applications portant sur le traitement automatique du langage naturel.

Ainsi, pour construire une application NLP, nous pouvons définir son architecture en deux étapes principales :

- **Le Prétraitement des données,**
- **Et le développement de l'algorithme.**


II- Architecture d'une application de TALN

1. Le Prétraitement des données : utilités

Traiter le langage naturel nécessite l'analyse de différents niveaux de compréhension/compétence :

- **Niveau lexical** : concerne les conventions sur les mots simples (exple : savoureux, *reuxsavou)
- **Niveau syntaxique** : concerne l'ordre correct des mots et son impact sur le sens de la phrase (le chien a mordu l'enfant, l'enfant a mordu le chien)
- **Niveau sémantique** : concerne la signification des mots et des phrases (la gorge brûle, la maison brûle, la soupe brûle)
- **Niveau pragmatique** : il concerne le contexte communicatif et social et son impact sur l'interprétation (c'est sympa, le sandwich demande une autre bière)
- Etc.

II- Architecture d'une application de TALN



II- Architecture d'une application de TALN

1. Le Prétraitement des données

Le prétraitement de texte est le processus de nettoyage, de structuration et de normalisation des données de texte avant qu'elles ne soient utilisées pour des tâches de traitement du langage naturel telles que l'apprentissage automatique ou l'analyse de texte.

En d'autres termes, cette étape consiste à préparer et à « nettoyer » les données pour que les machines puissent les exploiter. Elle met également en évidence les caractéristiques des textes avec lesquelles un algorithme peut fonctionner.


Le prétraitement des données peut inclure des tâches telles que la tokenisation, la lemmatisation, la radicalisation, la suppression des mots vides, la correction orthographique, la gestion de la ponctuation, etc.

II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ La tokenisation

Cette étape consiste à diviser le texte en mots ou phrases individuels, appelés jetons (**tokens**). Il s'agit d'une étape cruciale pour de nombreuses tâches de traitement du langage naturel, car elle permet au modèle d'analyser chaque mot ou phrase indépendamment. Cette étape permet également d'éliminer les caractères tels que les ponctuations ou les émojis.



II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ La tokenisation : Exemple de code python

```
import nltk
nltk.download('punkt') # Téléchargement des données nécessaires pour la tokenisation

# Example of text
texte = "This is the first step in the NLP pipeline."

# Tokenization in text
phrases = nltk.sent_tokenize(texte, language='english')
print("Tokenization in text:")
print(phrases)

# Tokenization in words
mots = nltk.word_tokenize(texte, language='english')
print("\nTokenization in words:")
print(mots)
```

```
Tokenization in text:
['This is the first step in the NLP pipeline.']
```

```
Tokenization in words:
['This', 'is', 'the', 'first', 'step', 'in', 'the', 'NLP', 'pipeline', '.']
```

II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ Lemmatisation

La lemmatisation est le processus de réduction des mots dans leur dictionnaire. Cette technique est utilisée pour réduire un mot à sa forme de base, ou autrement dit à sa racine. Ensuite, les différentes formes d'un même mot sont regroupées. Cette approche nécessite également des dictionnaires détaillés dans lesquels l'algorithme peut rechercher et relier les mots à leurs radicaux. La lemmatisation prend également en compte le contexte du mot pour identifier les différents sens qu'il peut avoir.



II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ Lemmatisation :

• Définition formelle

Soit un mot w appartenant au vocabulaire V . La **lemmatisation** est une fonction : $L:V \rightarrow \Lambda$

Où Λ (lambda) est l'ensemble des **lemmes** (formes canoniques des mots).

Ainsi, pour chaque mot w , on associe un lemme ℓ : $L(w)=\ell$

• Relation avec morphologie

Un mot w peut être vu comme une combinaison : $w=f(\ell,m)$

- ✓ ℓ : le lemme (racine canonique)
- ✓ m : les traits morphologiques (temps, nombre, genre, mode, etc.)
- ✓ f : fonction de génération morphologique

La lemmatisation est donc l'opération inverse : $L(w)=\ell$ tel que $w=f(\ell,m)$

Exercice : En se basant sur la relation avec morphologie donnez celle du mot « **Giving** »

II- Architecture d'une application de TALN

1. Le Prétraitement des données

❑ Lemmatisation Exemple de programme pour comprendre la Lemmatisation

```
import nltk
from nltk.stem import WordNetLemmatizer
wordnet_lemmatizer = WordNetLemmatizer()
text = "studies studying cries cry"
tokenization = nltk.word_tokenize(text)
for w in tokenization:
    print("Lemma for {} is {}".format(w, wordnet_lemmatizer.lemmatize(w)))
```

```
Lemma for studies is study
Lemma for studying is studying
Lemma for cries is cry
Lemma for cry is cry
```

II- Architecture d'une application de TALN

1. Le Prétraitement des données

❑ Radicalisation (Stemming)

La radicalisation est le processus de réduction d'un mot à sa racine de mot en supprimant les préfixes ou le suffixes. Pour ce faire, il coupe la fin ou le début des mots.

Studies



Studi



Giving



Giv

Buying



Buy

II- Architecture d'une application de TALN

1. Le Prétraitement des données

❑ Radicalisation (Stemming) : Exemple de programme pour comprendre le Stemming

```
import nltk
from nltk.stem.porter import PorterStemmer
porter_stemmer = PorterStemmer()
text = "studies studying cries cry"
tokenization = nltk.word_tokenize(text)
for w in tokenization:
    print("Stemming for {} is {}".format(w,porter_stemmer.stem(w)))
```

```
Stemming for studies is studi
Stemming for studying is studi
Stemming for cries is cri
Stemming for cry is cri
```

II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ Radicalisation (Stemming) : Exercice

Reprendre ce code en passant une phrase complète puis vérifier le comportement en tant que sortie.

NB : Faites appel au module (**from nltk.tokenize import sent_tokenize, word_tokenize**) afin de découper la phrase en jeton.

II- Architecture d'une application de TALN

1. Le Prétraitement des données

Comparaison

Aspect	Lemmatisation	Racinisation
Formule	$L(w) = \ell$	$R(w) = \text{racine}(w)$
Résultat	Lemmes valides du vocabulaire	Segments tronqués, parfois non valides
Dépendance	Morphologie + contexte	Règles heuristiques simples
Exemple	"mangeais" → "manger"	"mangeais" → "mang"

II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ Tagging part-of-speech (POS)

C'est un procédé visant à assigner des propriétés grammaticales telles que des noms, des verbes, des adverbes ou des adjectifs à des mots. Les mots partagent les mêmes étiquettes POS suivent généralement la même structure syntaxique et sont utiles pour les processus basés sur des règles.

II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ Tagging part-of-speech (POS)

Et pour obtenir le modèle en
Langue française télécharger les
données à l'aide de la commande :
python -m spacy download fr_core_news_sm

```
import spacy

# Charger le modèle de langue française
nlp = spacy.load('fr_core_news_sm')

# Exemple de texte en français
text = "Le traitement du langage naturel avec Python est amusant et excitant."

# Traiter le texte
doc = nlp(text)

# Afficher les mots et leurs étiquettes POS
for token in doc:
    print(f'{token.text}: {token.pos_}')
```

```
Le: DET
traitement: NOUN
du: ADP
langage: NOUN
naturel: ADJ
avec: ADP
Python: PROPN
est: AUX
amusant: ADJ
et: CCONJ
excitant: VERB
.: PUNCT
```

II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ Suppression des mots vides

La suppression des mots vides (Stop Words) est une technique du NLP visant à supprimer les articles, les pronoms et les prépositions. Elle permet de libérer de l'espace dans la base de données et d'accélérer le temps de traitement.

Les mots vides tels que « le », « et », « ou », etc. sont des mots courants qui n'ajoutent pas beaucoup de sens au texte. Ces mots sont souvent supprimés pour réduire la dimensionnalité des données et se concentrer sur les mots les plus significatifs.

II- Architecture d'une application de TALN

1. Le Prétraitement des données

□ Sacs de mots

Ce modèle permet de compter les mots d'un texte. Pour ce faire, il crée une matrice d'occurrence pour le document d'entrée, sans tenir compte de la syntaxe ou de la sémantique. Cela permet ensuite de constituer un classificateur des caractéristiques. Toutefois, cette approche ne permet pas de faire une analyse contextuelle ou sémantique de l'entrée.

II- Architecture d'une application de TALN

2. Développement de l'algorithme : Concepts d'algorithme

Un algorithme est un ensemble de règles opératoires dont l'application permet de résoudre un problème.

L'algorithme NLP est un programme informatique à qui on a appris à identifier l'intention du locuteur grâce à une série d'exemples prédéfinis.

II- Architecture d'une application de TALN

2. Développement de l'algorithme

Une fois que les données sont prétraitées, la prochaine étape du NLP consiste à développer un algorithme pour les interpréter.

Il existe de nombreux algorithmes de NLP. Cependant, nous allons retenir les trois types d'approches couramment utilisées à savoir :

- la méthode basée sur les règles,
- la méthode basée sur le machine learning
- et celle basée sur le deep learning.

II- Architecture d'une application de TALN

2. Développement de l'algorithme

❑ la méthode basée sur les règles

Cette approche utilise un ensemble de règles manuscrites pour identifier les entités nommées en fonction de leurs caractéristiques morphologiques et de leur contexte.

Ici, il est question de règles linguistiques élaborées spécifiquement pour un domaine. Ces règles permettent de résoudre des problèmes assez simples, comme l'**extraction des données structurées** à partir de données non structurées. Cette technique permet, par exemple, de classer les mails indésirables dans les spams. La règle à ce niveau serait de filtrer des termes spécifiques comme « offres » ou « promotion ».

II- Architecture d'une application de TALN

2. Développement de l'algorithme

□ la méthode basée sur le machine Learning

Cette approche utilise des algorithmes d'apprentissage automatique pour entraîner un modèle sur un grand corpus de texte pré-balisé, puis utiliser ce modèle pour prédire les entités nommées dans un nouveau texte.

Plus axée dans la compréhension du langage que la méthode basée sur les règles, l'approche par le ML permet de résoudre des problèmes plus difficiles. Grâce à la capacité d'apprentissage automatique, les algorithmes du ML peuvent également se référer à la longueur des phrases ou à l'occurrence de mots spécifiques. Généralement, ils utilisent des méthodes statistiques.

II- Architecture d'une application de TALN

2. Développement de l'algorithme

□ la méthode basée sur le Deep Learning.

A la différence du ML, le DL, une des sous-branches du ML, utilise **plusieurs couches de réseaux neuronaux**. Ces couches peuvent servir d'extracteurs automatiques des caractéristiques, ce qui signifie que cette méthode ne nécessite pas un prétraitement complexe. Etant plus puissants, les algorithmes du Deep Learning permettent alors d'effectuer des tâches qui sont encore plus difficiles, comme la **traduction**.

Le point commun entre ces deux dernières méthodes est qu'elles peuvent affiner leurs propres règles grâce à un **apprentissage itératif**.

III- Les outils Python pour la création d'un modèle NLP

□ Introduction

Les langages de programmation les plus utilisés dans le développement des applications NLP sont Python ou R. Ces langages disposent différentes bibliothèques contenant des règles et des méthodes qui permettent aux ordinateurs de classer les segments de textes.

Dans cette partie du cours, nous allons plus nous intéresser aux bibliothèques Python les plus utilisées pour le développement des applications NLP.

III- Les outils Python pour la création d'un modèle NLP

1. nltk (Natural Language Toolkit)

Le nltk est une bibliothèque logicielle en Python permettant un traitement automatique des langues. Elle est développée par Steven Bird et Edward Loper du département d'informatique de l'université de Pennsylvanie. C'est l'une des bibliothèques de traitement naturel du langage les plus puissantes.

Cette suite d'outils rassemble les algorithmes les plus communs du traitement naturel du langage comme le tokenizing, le part-of-speech tagging (POS), le stemming, l'analyse de sentiment, la segmentation de topic ou la reconnaissance d'entité nommée.

III- Les outils Python pour la création d'un modèle NLP

1. nltk (Natural Language Toolkit)

NLTK peut être également considéré comme une plate-forme leader pour la création de programmes **Python** compatibles avec les données de langage humain. Il fournit des interfaces faciles à utiliser pour plus de 50 corpus et ressources lexicales telles que WordNet, ainsi qu'une suite de bibliothèques de traitement de texte pour la classification, la tokenisation, le et un forum de discussion actif.

Historique des versions de NLTK

Version	Date de sortie
3.2.4 (dernier)	2017-05-21
3.2	2016-03-03
3.1	2015-10-15

III- Les outils Python pour la création d'un modèle NLP

1. nltk (Natural Language Toolkit)

- **Fonction de téléchargement de NLTK**

Vous pouvez installer NLTK à l'aide de la commande **pip install nltk**. Après son installation, de nombreux composants ne seront plus présents et vous ne pourrez pas utiliser certaines fonctionnalités de NLTK. À partir de votre shell Python, exécutez la fonction `nltk.download()` pour sélectionner les packages supplémentaires que vous souhaitez installer à l'aide de l'interface utilisateur.

III- Les outils Python pour la création d'un modèle NLP

1. nltk (Natural Language Toolkit)

- **Exemples avec NLTK**

Vous pouvez utiliser NLTK (en particulier le package `nltk.tokenize`) pour effectuer la détection des limites de phrase :

```
import nltk
text = "This is a test. Let's try this sentence boundary detector."
text_output = nltk.tokenize.sent_tokenize(text)
print('text_output: {}'.format(text_output))
```

```
text_output: ['This is a test.', "Let's try this sentence boundary detector."]
```

III- Les outils Python pour la création d'un modèle NLP

2. spaCy

spaCy est **une bibliothèque Python gratuite et open source** publiée sous la licence MIT pour le traitement naturel du langage (Natural Language Processing ou NLP). Elle est écrite en Cython, et conçue pour l'usage en production grâce à une API concise et simple d'utilisation.

Cette bibliothèque est **initialement développée par Matt Honnibal de Explosion AI**. Pour les connaisseurs du langage Python, on peut considérer spaCy comme l'équivalent de numPy pour le NLP : une bibliothèque de bas niveau, mais intuitive et performante.

Grâce à cet outil, il est possible de créer des applications permettant **de traiter et de comprendre de larges volumes de texte**. Il peut être utilisé notamment pour développer des systèmes d'extraction d'information, de compréhension du langage naturel, ou encore pour pré-traiter des textes pour le Deep Learning.

III- Les outils Python pour la création d'un modèle NLP

2. spaCy

- **Les outils et fonctionnalités spaCy**

spaCy peut être utilisé pour **une large variété de tâches liées à des projets NLP**. Il permet par exemple la Tokenization, la Lemmatisation, le tagging POS, la reconnaissance de phrase ou d'entité, l'analyse des dépendances, la transformation mot / vecteur et d'autres techniques de normalisation et de nettoyage.

- **Fonction de téléchargement de spaCy**

Vous pouvez installer spaCy à l'aide de la commande **pip install spaCy**